

第五部分

推荐系统进阶

第 19 章 推荐系统偏差问题

在本书上册的前 18 章中，我们系统介绍了工业级推荐系统的整体架构、核心模块以及典型工程实践，并结合大量工业案例对实际系统开发过程中可能遇到的性能优化、系统稳定性以及工程实现等问题进行了深入讨论。然而，在实际推荐系统的开发与应用过程中，除了需要关注系统架构、模型结构以及工程效率之外，还需要重点关注一个更加基础但又容易被忽视的问题，即推荐系统中的**偏差（Bias）**。

推荐系统本质上是一个数据驱动的决策系统。模型通过用户历史行为学习用户兴趣，并根据学习到的偏好对候选内容进行排序和推荐。因此，训练数据如何产生、用户行为如何被记录、内容如何获得曝光以及不同用户和内容获得多少流量，都会直接影响模型最终学习到的推荐偏好。与传统监督学习任务不同，推荐系统中的训练数据并不是从一个独立同分布的数据集上随机采样得到的，而往往是由历史推荐系统自身的决策过程产生的。换言之，**推荐系统既在利用历史数据进行学习，同时又在不断创造新的训练数据**。

这一特点使得推荐系统天然存在较为复杂的反馈闭环。模型根据历史数据进行推荐，用户对推荐结果产生点击、播放、点赞、评论以及关注等行为，这些行为进一步成为下一轮模型训练的数据，而下一轮模型又会改变后续的曝光分布。随着这一过程不断迭代，原有的数据分布可能被进一步放大，从而形成明显的偏差甚至反馈循环。例如，一个内容由于早期获得了更多曝光而积累了较多交互数据，模型可能进一步认为该内容具有更高的用户价值，从而给予它更多曝光；而原本质量较高但缺少初始曝光的新内容，则可能因为缺少行为数据而持续得不到流量。

因此，推荐系统中的偏差并不只是一个简单的统计问题，而是贯穿数据采集、样本构造、模型训练、在线排序、用户交互以及内容供给整个推荐链路的系统性问题。偏差一方面会导致训练数据与真实用户偏好之间存在偏离，使模型学习到并不完全可靠的相关性；另一方面还可能进一步影响线上流量分配，使不同用户群体、不同内容类型以及不同曝光位置之间形成不合理的流量差异。

从工业推荐系统的角度来看，常见的推荐偏差主要包括**样本选择偏差、用户群体偏差、混淆偏差、曝光位置偏差、Duration 偏差以及流行度偏差**等。不同偏差产生的原因并不相同，其影响范围也存在明显差异。例如，样本选择偏差主要来源于训练数据并非随机采样，容易造成线上线下分布不一致；用户群体偏差主要来源于不同用户之间数据量和行为模式的不均衡，容易导致模型对活跃用户和冷启动用户产生不同程度的建模能力；曝光位置偏差则来源于用户对不同展示位置上的内容具有不同的交互概率；Duration 偏差在短视频等场景中尤其突出，模型可能由于目标定义或评价指标的原因，对不同视频时长产生系统性的偏好；流行度偏差则可能使热门内容获得更多曝光，进一步强化其热门程度，从而形成明显的马太效应。

需要特别注意的是，不同类型的偏差之间并不是相互独立的。在真实工业系统中，它们往往会相互叠加。例如，热门内容更容易获得高曝光位置，而高曝光位置又会带来更多交互数据，更多交互数据进一步提高内容的流行度，最终形成位置偏差、样本选择偏差与流行度偏差相互强化的反馈循环。因此，推荐偏差问题不能简单地通过修改某一个模型结构来解决，而需要结合数据、模型、排序策略以及线上流量机制进行系统治理。

本章将从工业推荐系统的实际数据生成过程出发，对上述典型偏差问题进行系统介绍，并分析不同偏差对推荐模型训练和线上推荐效果的影响。在后续章节中，本书还将进一步结合因果推断、多目标优化、强化学习以及生成式推荐等技术，讨论如何从更深层次解决推荐系统中的偏差与优化问题。

19.1 推荐偏差问题概述

工业级推荐系统通常采用典型的级联式架构，包括召回、过滤、粗排、精排、重排以及混排等多个阶段。一个用户请求进入推荐系统后，并不是从全部内容中直接选择最终推荐结果，而是经过多个模块逐步筛选。例如，系统可能首先从百万甚至千万级内容库中召回数千个候选内容，再经过过滤和粗排缩小候选集合，随后由精排模型进一步计算用户与内容之间的多目标预估分数，最终通过重排和业务策略生成用户实际看到的推荐列表。

这一过程决定了用户最终看到的数据只是整个内容空间中的一个非随机子集。用户没有点击某个内容，并不意味着用户不喜欢这个内容，因为用户可能根本没有看到它；一个内容获得较高的播放量，也不完全意味着

其本身质量更高，因为它可能只是获得了更多曝光机会。因此，推荐系统中的观测行为与真实用户偏好之间通常并不能直接画等号。

我们可以将用户对内容的真实偏好、系统是否曝光内容以及用户最终产生的行为简单区分为三个层次。首先，用户可能对某个内容存在潜在兴趣；其次，推荐系统需要决定是否以及以什么位置向用户展示该内容；最后，只有当内容真正获得曝光后，用户才可能产生点击、播放、点赞、评论等可观测行为。因此，实际训练数据通常是多个决策过程共同作用后的结果。这一过程可以抽象表示为如下图19.1所示的过程。其中，用户真实偏好通常无法被直接观测，而推荐系统能够获得的主要是曝光之后产生的行为数据。这意味着训练数据中天然混合了用户偏好、推荐策略以及曝光机制等多方面因素。




图 19.1: 推荐系统中用户偏好、曝光机制与行为观测之间的关系。

在工业推荐系统中，偏差问题通常具有以下几个典型特点：

- 首先，**偏差具有数据生成属性**。训练数据并不是自然产生的，而是历史推荐系统不断进行推荐决策之后形成的。模型本身的历史决策会改变未来的数据分布。
- 其次，**偏差具有累积效应**。某一种轻微的偏差如果持续存在，可能会随着推荐反馈循环不断被放大。例如热门内容获得更多曝光、更多曝光产生更多交互、更多交互又进一步提升模型对热门内容的判断，最终导致流量高度集中。
- 再次，**偏差具有链路传递性**。推荐系统不同阶段之间并非独立运行，召回阶段的候选分布会影响粗排，粗排的候选分布会影响精排，而精排和重排的最终决策又会影响下一轮训练数据。因此，一个阶段产生的偏差可能被后续阶段继承甚至放大。
- 最后，**偏差具有业务相关性**。同一种偏差在不同业务场景中的影响可能完全不同。例如，在短视频场景中，Duration 偏差可能直接影响内容供给结构；在电商场景中，流行度偏差可能导致头部商品获得过多曝光；在广告场景中，位置偏差则可能显著影响 CTR 预估。

因此，在设计工业推荐模型时，不能仅仅关注模型离线 Loss 或者 AUC 等指标，还需要分析训练数据和线上流量分布是否存在系统性偏差，并判断模型是否正在利用某些与真实用户价值并不完全一致的“捷径”。

19.2 样本选择偏差

样本选择偏差 (Sample Selection Bias) 是工业推荐系统中最基础、也最常见的一类偏差问题，其定义如下：

定义 19.1 (样本选择偏差)

推荐系统训练数据的观测或选取机制并非无偏随机的观测，导致其分布相对于目标总体分布产生系统性偏离的现象，称为样本选择偏差。

具体来说，假设用户集合为 $\mathcal{U}$ ，内容集合为 $\mathcal{I}$ ，我们在理想情况下希望模型能够学习任意用户 $u \in \mathcal{U}$ 与任意内容 $i \in \mathcal{I}$ 之间的潜在匹配关系。然而在实际系统中，用户只会看到其中很小一部分内容。可以定义曝光变量

$e_{ui} \in \{0, 1\}$:

$$e_{ui} = \begin{cases} 1, & \text{if item } i \text{ is exposed to user } u, \\ 0, & \text{otherwise} \end{cases} \quad (19.1)$$

用户行为标签 y_{ui} 通常只有在 $e_{ui} = 1$ 时才能被可靠地观测。因此，实际训练数据更接近：

$$\mathcal{D} = \{(u, i, y_{ui}) \mid e_{ui} = 1\} \quad (19.2)$$

而不是完整的用户与内容组合：

$$\mathcal{U} \times \mathcal{I} \quad (19.3)$$

这意味着训练数据本身已经经过历史推荐策略筛选。

我们可以看出，模型实际上是在历史推荐系统已经选择过的数据上学习下一代推荐系统。例如，在一个短视频推荐系统中，系统可能每天从数千万条内容中向用户实际曝光数百条内容。如果用户没有观看过某个视频，则可能有两种完全不同的原因：第一种情况是用户看到了该视频，但主动选择跳过该视频；另外一种情况是该视频从未进入到用户的曝光列表中，所以用户根本没有机会看到它。我们在做模型优化时如果直接将两种情况都当为“负反馈”处理，那么模型就可能错误地将大量未知偏好（Unknown Preference）理解为负向的偏好。

除此之外，样本选择偏差还会造成明显的模型线上线下不一致问题，即模型训练阶段使用的是历史曝光分布，而在线上系统中则面对的是当前完整的候选空间。随着模型不断更新，召回策略、粗排模型和精排模型都会发生变化，新的线上候选分布可能逐渐偏离历史训练数据分布。当模型在训练数据中学习到的相关性无法迁移到新的候选分布时，就会产生明显的泛化问题。

在工业级推荐系统中，级联式推荐架构通常会进一步放大这一问题。假设召回阶段从物品库中选择 N_r 个候选物品，粗排阶段进一步选择 N_c 个候选物品，精排阶段再选择 N_p 个候选物品。整个过程可以表示为如下形式：

$$\mathcal{I}^r \supset \mathcal{I}^c \supset \mathcal{I}^p \supset \mathcal{I}^f \quad (19.4)$$

其中， $\mathcal{I}^r$ 是召回阶段的候选集合， $\mathcal{I}^c$ 是粗排阶段的候选集合， $\mathcal{I}^p$ 是精排阶段的候选集合， $\mathcal{I}^f$ 是最终曝光集合。从这个公式可以看出，越靠后的阶段看到的内容集合越小。因此，一个内容如果没有进入到最终的曝光集合中，这并不一定意味着它的用户价值较低，而可能是在更早的阶段就被前链路的模块过滤掉了。特别是在粗排模型和精排模型目标不一致的情况下，粗排模型可能提前过滤掉一些精排模型原本具有较高价值的内容，从而导致精排模型长期无法获得这些内容上的有效训练样本。这类问题可以形成典型的**级联选择偏差（Cascaded Selection Bias）**，如图19.2所示。上游模块的选择决定了下游模块能够看到什么数据，而下游模型又通过新的线上结果反过来影响下一轮训练数据。



图 19.2: 级联选择偏差示意图。

样本选择偏差还会进一步影响内容供给侧。例如，在短视频平台中，如果历史模型更加偏好某一 Duration 区间的视频，那么该区间的视频会获得更多曝光并积累更多正反馈数据。模型在下一轮训练中又会看到更多该区间的视频样本，最终可能形成“某类视频更容易获得曝光 → 获得曝光后产生更多训练数据 → 模型进一步偏好该类视频”的循环。

因此，样本选择偏差不仅影响模型训练准确性，还可能进一步改变平台的内容生态和供给结构。在工业实践中，常见的缓解方法包括扩大训练样本覆盖范围、引入随机探索样本、增加跨阶段样本、进行重要性加权（Importance Weighting）、采用逆倾向得分（Inverse Propensity Score）进行校正，以及通过在线探索机制获得更加接近随机分布的数据等。后续章节还会结合因果推断进一步讨论如何从曝光机制出发解决这一问题。

19.3 用户群体偏差

用户群体偏差（User Group Bias）是指由于不同用户群体在用户属性、活跃程度、历史行为数量以及内容消费习惯等方面存在明显差异，使推荐模型对不同用户群体产生不均衡的建模能力。工业推荐系统通常同时服务于大量具有不同特征的用户。例如，有些用户每天使用推荐系统数小时并产生大量点击、播放、点赞和评论行为，而另一些用户可能只有很少的历史行为。对于活跃用户而言，模型可以从大量历史行为中较准确地学习其兴趣；而对于低活跃用户、新用户以及新设备用户，模型可利用的信息则非常有限。

因此，我们可以定义用户 u 的历史行为数量为 n_u 。当不同用户的 n_u 存在较大差异时，训练数据中不同用户的有效信息量也会存在明显差异：

$$n_{u_1} \gg n_{u_2} \quad (19.5)$$

这会导致模型更加容易拟合高活跃用户，而对于低活跃用户的兴趣建模能力相对较弱。在实际推荐系统中，用户群体偏差主要体现在以下几个方面。

- 第一，**活跃度偏差**。高活跃用户产生大量行为，因此在训练数据中出现频率更高，模型参数更容易受到高活跃用户影响。
- 第二，**冷启动偏差**。新用户缺乏历史行为，模型只能依赖人口属性、设备信息、地域、实时行为以及热门内容等有限信息，因此新用户的推荐结果通常与成熟用户存在较大差异。
- 第三，**兴趣结构偏差**。不同用户群体可能具有完全不同的内容消费结构。例如，一部分用户主要消费娱乐内容，另一部分用户主要消费知识内容。如果训练数据中某类用户占据绝对多数，模型可能更加倾向于学习主流用户的兴趣模式。
- 第四，**长尾用户偏差**。少量行为用户在整个训练数据中的贡献较小，但这些用户并不意味着没有明确兴趣，只是其兴趣信号更加稀疏。如果模型简单地以全局平均效果为目标，可能牺牲这部分用户的推荐体验。

用户群体偏差与样本选择偏差之间往往存在显著的相互强化关系。以用户活跃度为例，高活跃用户会产生更多点击、观看、互动等行为，因此在训练数据中拥有更丰富的样本覆盖；更充足的训练样本又使模型能够更准确地刻画其兴趣偏好，并提供更匹配的推荐结果；推荐质量的提升进一步促进用户持续使用，从而形成“高活跃 → 更多样本 → 更优推荐 → 更高活跃”的正向循环。

与之相对，低活跃用户的历史行为较少，可用于训练和建模的样本相对不足，导致模型对其兴趣和需求的预测能力较弱。当推荐质量下降时，这部分用户可能进一步减少使用频率，使后续可观测行为继续减少，最终形成“低活跃 → 样本稀缺 → 预测不准 → 体验下降 → 更低活跃”的负向循环。由此可见，用户群体差异不仅会影响模型的离线训练效果，也会通过线上反馈机制被持续放大。

因此，工业推荐系统通常需要针对不同用户群体开展分层分析，而不能仅依赖整体 AUC、CTR 或 Duration 等汇总指标。例如，可以按照用户活跃度、新老用户、历史行为长度等维度，对不同群体分别统计模型效果：

$$\text{Metric} = \{M_{\text{new}}, M_{\text{low-active}}, M_{\text{mid-active}}, M_{\text{high-active}}\} \quad (19.6)$$

只有当整体指标提升的同时，核心用户群体的体验没有出现明显恶化，模型优化才能被认为具有更稳定、更可靠的实际收益。否则，整体指标的改善可能只是由高活跃用户或样本充足群体驱动，而掩盖了部分关键用户群体的性能下降。

针对用户群体偏差，工业级推荐系统通常会综合采用分人群采样、分人群加权、用户分层建模、多任务学习、Meta Learning 以及冷启动专用模型等方法。同时，在训练与评估阶段引入更细粒度的分群指标，也有助于及时发现整体指标无法反映的局部体验问题，避免模型优化对部分用户群体造成隐性损害。

总体而言，用户群体偏差是工业推荐系统中难以完全避免的问题。在实际算法优化过程中，工程师通常需

要围绕不同用户群体进行精细化分析、建模与策略设计，而不能仅以整体指标作为唯一决策依据。具体到模型训练层面，可以在网络结构中引入面向不同人群的 **Tower**，通过分群建模学习差异化的用户表示和预测能力，从而更充分地捕捉不同群体的偏好特征。在线上推理与策略层面，则可以针对不同用户群体设计差异化的排序、召回或曝光策略，在兼顾整体效果的同时，持续提升各类核心用户群体的推荐体验。

19.4 混淆偏差

在推荐系统的观看时长预估中，时长预估模型学习到的特征与观看时长之间的相关关系并不一定完全来源于真实的用户偏好或内容因素，还可能受到一些额外因素的共同影响。这类由于混淆因素（**Confounder**）导致模型错误学习变量之间相关关系的问题，被称为**混淆偏差（Confounding Bias）**。简单来说，如果某个因素同时影响模型输入特征 X 和目标变量 T ，那么模型在观察到 X 与 T 之间的相关性时，可能会将原本由该因素产生的影响错误归因于 X 。

以短视频推荐中的观看时长预估为例，假设 X 表示用户和视频相关特征， T 表示用户对视频的观看时长，而 D 表示曝光位置、流量环境或者其他影响用户观看行为的因素。此时可能存在如下关系：

$$D \rightarrow X, \quad D \rightarrow T, \quad X \rightarrow T \quad (19.7)$$

其中， D 同时影响输入特征 X 和观看时长 T ，因此 D 是典型的混淆因素。例如，一个视频长期获得较好的推荐位置，因此具有更高的曝光质量和更大的用户观看概率。模型在训练数据中可能观察到该视频相关特征 X 与观看时长 T 之间存在较强的正相关，并进一步学习为“该视频特征能够带来更长的观看时长”。但实际上，其中一部分收益可能来源于更好的曝光环境 D 。如果模型无法区分视频特征本身的影响与曝光环境带来的影响，就可能将 D 对观看时长的作用错误归因于 X ，从而产生混淆偏差。

这种问题在推荐系统中尤其值得关注，因为推荐数据通常来自已有推荐策略产生的观测数据，而不是严格意义上的随机实验。模型所看到的用户行为已经受到历史排序策略、曝光机制、流量分配以及用户群体差异等因素影响。因此，直接学习观测分布：

$$E(T | X) \quad (19.8)$$

得到的结果可能混入混淆因素的影响，并不一定能够反映在控制其他因素之后 X 对 T 的真实作用。从因果推断的角度来看，更希望估计的是在对 X 进行干预之后观看时长的期望，即：

$$E(T | do(X)) \quad (19.9)$$

其中， $do(X)$ 表示人为干预输入特征 X ，从而切断混淆因素对 X 的影响。对于满足上述因果关系的混淆因素 D ，可以通过后门准则调整（**Backdoor Adjustment**）来对不同混淆因素取值下的条件结果进行加权：

$$E(T | do(X)) = \sum_d P(D = d) E(T | X, D = d) \quad (19.10)$$

其中， $P(D = d)$ 表示混淆因素在整体数据分布中的先验概率。直观而言，该过程并不是简单地使用当前样本所处的混淆因素状态进行预测，而是分别估计不同混淆因素条件下的观看时长，再按照整体数据中的真实分布进行加权，从而降低特定曝光环境或样本分布对模型预测结果的影响。

19.5 曝光位置偏差

曝光位置偏差（**Position Bias**）是推荐系统中一种非常典型的曝光机制偏差。它来源于用户注意力在展示列表中的非均匀分布：用户通常更容易注意到、浏览或点击靠前位置的内容。更具体地说，曝光位置偏差可以定义如下：

定义 19.2 (曝光位置偏差)

即使两个内容本身具有完全相同的用户价值，由于展示位置不同，用户与其发生交互的概率也可能不同。



具体来说，假设一个推荐列表包含 N 个内容：

$$[i_1, i_2, \dots, i_N] \quad (19.11)$$

用户通常会按照从前到后的顺序浏览这些内容，因此排在前面的内容具有更高的曝光机会和注意力。可以定义位置 k 对用户交互概率产生的影响为 b_k ，则一个简化的点击模型可以表示为：

$$P(y_{ui} = 1) = f(x_{ui}) \cdot b_k \quad (19.12)$$

其中 $f(x_{ui})$ 表示用户与内容之间的真实匹配程度，而 b_k 表示位置带来的额外影响。

如果直接使用用户点击作为监督信号，而没有考虑位置因素，那么模型可能错误地认为排在前面的内容具有更高的用户价值。由于排序模型本身又决定内容的位置，因此这种偏差容易形成反馈循环，如下图19.3所示。这种现象在 CTR 预估、广告排序以及信息流推荐中尤其明显。



图 19.3: 曝光位置偏差的反馈循环示意图。

位置偏差不仅影响训练样本的曝光分布，也会通过历史日志中的监督信号传递到后续模型训练中。以精排 CTR 模型为例，历史点击标签同时受内容质量、用户兴趣和曝光位置影响：排在靠前位置的内容更容易被用户浏览和交互。因此，模型若直接拟合历史点击、时长或点赞等标签，学习到的往往是“用户与内容匹配质量”与“历史位置策略”的混合信号，而非纯粹的用户偏好。

假设内容 i 在请求 x 下展示于位置 p_i ， y_i 为观测到的点击或交互标签， o_i 表示用户是否实际浏览到该内容。则 $y_i = 1$ 的概率可以分解为：

$$\Pr(y_i = 1 \mid x, i, p_i) = \Pr(o_i = 1 \mid x, i, p_i) \cdot \Pr(y_i = 1 \mid x, i, p_i, o_i = 1) \quad (19.13)$$

在常用的浏览假设 (examination hypothesis) 下，用户只有先浏览到内容，才可能产生点击、点赞等后续交互。进一步地，如果认为“是否浏览到内容”主要由其展示位置决定，而用户在浏览内容后的交互倾向主要由用户、内容及上下文决定，则可作如下近似：

$$\Pr(o_i = 1 \mid x, i, p_i) \approx e(p_i) \quad (19.14)$$

$$\Pr(y_i = 1 \mid x, i, p_i, o_i = 1) \approx q(x, i) \quad (19.15)$$

其中， $e(p_i)$ 表示位置 p_i 的浏览倾向（即该位置上的内容被用户实际浏览到的概率）， $q(x, i)$ 表示在给定用户请求和内容后，用户已经浏览到该内容时产生交互的条件概率，可理解为更接近用户与内容匹配质量的交互倾向。代入上式可得：

$$\Pr(y_i = 1 \mid x, i, p_i) \approx e(p_i) \cdot q(x, i) \quad (19.16)$$

在模型训练阶段，更常见做法是对单个样本的 label 或者 reward 信号进行位置倾向校正。以逆倾向得分加权 (Inverse Propensity Weighting, IPW) 为例，位置 p_i 对应的样本权重定义为：

$$w_i = \frac{1}{e(p_i)} \quad (19.17)$$

因此，我们可以将模型的训练损失函数改写成为加权的经验风险损失函数，即：

$$\mathcal{L}_{\text{IPW}} = \frac{1}{N} \sum_{i=1}^N w_i \cdot \ell(y_i, \hat{y}(x_i, v_i)) \quad (19.18)$$

其中, $\ell(\cdot)$ 可以是点击、时长、点赞或多目标 **reward** 的训练损失。该方法会相对提高低曝光位置样本的训练权重, 减弱高曝光位置样本因天然更容易被观察而产生的过度影响。而对于播放时长等连续 **reward**, 也可以先构造位置校正后的训练目标:

$$\tilde{r}_i = \frac{r_i}{\max(e(p_i), \epsilon)} \quad (19.19)$$

其中, ϵ 用于避免低倾向位置产生过大的权重。考虑到完整 **IPW** 可能带来高方差, 工业实践中通常还会采用权重截断或归一化, 例如:

$$w_i^{\text{clip}} = \min\left(\frac{1}{e(p_i)}, w_{\max}\right) \quad (19.20)$$

需要注意的是, 位置倾向 $e(p)$ 不能简单地由历史位置的点击率来进行估计, 因为历史排序策略本身会将不同质量的内容放在不同位置。更可靠的做法是在有限的探索流量中进行适当的随机化, 比如对最终的候选集进行随机打散、对相邻位置的 **item** 进行随机交换或局部随机排序, 然后再估计不同位置下用户的真实浏览概率; 最后将该倾向估计的概率应用到模型训练和离线评估中。

上面这种权重截断的方式虽然能够直接限制极低倾向样本的影响, 但依然会改变原始 **IPW** 的权重尺度。另一种常用的稳定化方式是自归一化逆倾向得分 (**Self-Normalized Inverse Propensity Scoring, SNIPS**)。它的基本思想是在一个训练批次或评估样本集合内, 不直接使用原始权重 $w_i = \frac{1}{e(p_i)}$, 而是将其除以该集合的平均权重, 得到归一化后的权重。因此, w_i 被替换为归一化后的权重 $\bar{w}_i$, 即:

$$\bar{w}_i = \frac{\frac{1}{e(p_i)}}{\frac{1}{N} \sum_{j=1}^N \frac{1}{e(p_j)}} \quad (19.21)$$

相应地, **SNIPS** 形式的加权训练损失可以写为:

$$\mathcal{L}_{\text{SNIPS}} = \frac{1}{N} \sum_{i=1}^N \bar{w}_i \cdot \ell(y_i, \hat{y}(x_i, v_i)) \quad (19.22)$$

与前述的 **IPW** 方法相比, **SNIPS** 方法保持了样本之间由逆倾向得分决定的相对权重, 同时将一个批次内的平均权重归一化为 1。因此, 当少量低曝光位置样本具有很大的原始权重时, **SNIPS** 可以降低整体损失尺度随曝光分布波动而剧烈变化的问题, 通常具有更好的数值稳定性和更低的估计方差。相应地, 其代价是在有限样本下可能引入轻微偏差。

在此基础上, 还可以进一步使用 **Doubly Robust (DR)** 方法或反事实学习排序方法。**DR** 方法同时训练 **reward** 模型与位置倾向模型: **reward** 模型直接预测样本的预期收益, 逆倾向加权项则用于校正预测值与观测标签之间的残差。以 $\hat{r}(x_i, v_i)$ 表示 **reward** 模型预测, **DR** 形式的样本收益估计可写为:

$$\hat{r}_i^{\text{DR}} = \hat{r}(x_i, v_i) + \frac{y_i - \hat{r}(x_i, v_i)}{e(p_i)} \quad (19.23)$$

这种形式的直观含义是先利用 **reward** 模型给出一个较为稳定的收益预测, 再对其未能解释的观测残差进行逆倾向校正。当 **reward** 模型或倾向模型中至少有一个估计较准确时, **DR** 方法往往能够获得比单独使用 **IPW** 方法更稳健的效果。反事实学习排序则进一步以校正后的点击、时长或多目标 **reward** 为监督信号, 直接优化目标排序策略在不同曝光位置下的预期收益。这些方法的共同目标并不是让模型忽略位置因素, 而是将位置带来的可见性差异从历史交互信号中尽可能剥离, 避免模型将其错误归因于内容质量或用户偏好。

19.6 Duration 偏差

Duration 偏差是短视频推荐系统中特别值得关注的一类偏差。它主要是指推荐模型或者优化目标由于视频时长不同而产生系统性的内容偏好, 从而使模型更倾向于某些 **Duration** 区间的视频。在短视频场景中, 用户观看时长通常是一个重要的优化目标。相比点击或者播放等二值指标, 观看时长包含了更加丰富的用户反馈信息。然而, 如果直接使用绝对观看时长作为优化目标, 就可能产生明显的 **Duration** 偏差。

假设两个视频的实际观看时长分别为:

$$D_1 = 15s, \quad D_2 = 60s \quad (19.24)$$

而用户对这两个视频分别观看了：

$$W_1 = 12s, \quad W_2 = 30s \quad (19.25)$$

如果只比较绝对观看时长，则第二个视频显然具有更高的观看时长；但从观看完成比例来看：

$$\frac{W_1}{D_1} = 0.8, \quad \frac{W_2}{D_2} = 0.5 \quad (19.26)$$

因此，两个视频所表达的用户兴趣并不能简单地通过绝对观看时长来进行比较。这个问题在 EVTR、LVTR 等时长相关指标中更加明显。如果直接设置固定的观看时长阈值，例如：

$$y = \mathbb{I}(W > T) \quad (19.27)$$

那么对于短视频而言，该阈值可能相对较高，而对于长视频而言，该阈值可能又过低。不同 Duration 的视频在相同标签体系下实际上面临着不同的判定标准。更进一步，如果推荐系统直接优化绝对观看时长，那么模型可能通过推荐更长的视频获得更高的预估 Duration，即使用户对这些视频的真实兴趣程度并没有提高。反过来，如果模型过度优化观看完成率，又可能产生偏好极短视频的问题。因此，Duration 本身既是用户价值信号，同时也可能成为模型优化中的一个偏置来源。

除此之外，Duration 偏差还会影响到内容供给侧。如果某个 Duration 区间的视频更容易获得高模型分数，那么这类视频会获得更多曝光；更多曝光又会带来更多观看数据，最终导致内容生产者倾向于生产更加符合模型偏好的视频长度，从而改变整个内容生态。因此，在工业短视频推荐中，需要同时关注用户绝对播放时长、视频时长以及播放完成度等多方面因素。在模型设计上，也可以通过 Duration-aware 的标签、Duration-aware 的阈值、多任务学习、分布建模以及反事实校正等方式来降低模型学习中的 Duration 偏差。例如，可以根据视频时长 D 动态调整观看阈值 $T(D) = \alpha D$ ，其中 α 为与视频 Duration 相关的比例系数。相比固定阈值，这种方式能够使不同 Duration 的视频具有更加一致的评价标准。

需要注意的是，Duration 偏差并不意味着模型应该完全消除 Duration 信息。恰恰相反，视频 Duration 本身就是影响用户观看行为的重要因素。真正需要解决的是：区分 Duration 带来的合理用户行为差异，与模型由于目标定义不合理而产生的非预期偏好。关于 Duration 建模、Duration Bias 以及完整观看时长分布预测等问题，本书后续第23章节中将会在讨论时长预估方法的基础上也介绍一些时长纠偏建模相关的方法。

19.7 流行度偏差

推荐系统中往往存在较强的马太效应（Matthew Effect），即高热度内容由于积累了更多历史交互数据，更容易获得模型的青睐，并进一步获得更多曝光和用户反馈，最终形成“热门内容越来越热门”的正反馈循环。在工业推荐系统中，这种流行度偏差通常会直接反映在模型的预估结果上。例如，对于一个候选视频 i ，模型可能会输出多个用户行为维度的预估概率：

$$\mathbf{p}_i = [p_i^{(1)}, p_i^{(2)}, \dots, p_i^{(M)}] \quad (19.28)$$

其中不同维度分别对应点击、播放、点赞、关注、评论以及观看时长等用户行为。我们通常将模型输出不同维度的 $p^{(j)}$ 叫做 pxtr（predicted XTR），工业系统通常会进一步将多个维度的预估结果融合为一个综合的排序分数 s_i ，即：

$$s_i = f(p_i^{(1)}, p_i^{(2)}, \dots, p_i^{(M)}) \quad (19.29)$$

由于不同内容的历史曝光量、交互量以及流行度存在明显差异，模型在不同 pxtr 维度上可能存在不同程度的系统性 Bias。当这些 Bias 进一步经过多目标融合后，就可能被放大，并最终传递到上述的多目标融合形成最终排序分 s_i 的过程中，使得某些高热度内容获得额外的排序优势。

特别是在工业推荐系统中，一个重要的问题是：



笔记 模型预测到的高 pxtr 并不一定完全意味着当前用户对该内容具有更强的偏好，其中可能同时包含了内容历史流行度所带来的先验优势。因此模型预估的 pxtr 本身可能存在 Duration 偏差、流行度偏差等各种 bias。

例如，在同一个用户请求中存在两个候选视频 i_1 和 i_2 。假设模型预测二者的 pxtr 基本相同：

$$\text{pxtr}_{i_1} \approx \text{pxtr}_{i_2} \quad (19.30)$$

但如果 i_1 的历史曝光或者经验预估指标明显低于 i_2 ，即：

$$\text{empXTR}_{i_1} < \text{empXTR}_{i_2} \quad (19.31)$$

则可以认为 i_1 在较少历史曝光基础上已经获得了与 i_2 接近的模型预估结果。换言之，在当前用户请求中， i_1 可能具有更高的潜在用户匹配度，而 i_2 的高预估结果中可能包含更强的历史流行度因素。

基于这一观察，可以在粗排或者精排模块中增加一个用于流行度纠偏的队列，对候选内容进行额外的 **Debias** 评分。其核心思想是：在保持原始 pxtr 排序能力的基础上，适当提高低经验曝光但具有较高预测价值内容的竞争能力。具体而言，对于候选 **item** i ，可以定义其流行度纠偏分数为：

$$\text{debiasScore}_i = \sum_{m=1}^M \left(\alpha_m \frac{\text{pxtr}_i^{(m)}}{\text{empXTR}_i^{(m)} + \beta_m} \right) \quad (19.32)$$

其中， M 表示 pxtr 的预测维度， $\text{pxtr}_i^{(m)}$ 表示 **item** i 在第 m 个行为维度上的预估结果， $\text{empXTR}_i^{(m)}$ 表示对应维度的经验预估值， α_m 用于控制不同行为维度的纠偏权重， β_m 为平滑项，用于避免 empXTR 较小时分数出现过大的数值波动。

在实际工程中，并不一定直接使用 debiasScore 替代原始排序分数，通常是将其作为独立的纠偏队列进行候选物品的补充。例如，粗排阶段首先按照原始 pxtr 选择主要候选集合，同时按照 debiasScore 选择一部分具有潜在价值的低热度内容，再将两部分候选合并后进入后续排序阶段。或者采用统一的排序公式，只不过将纠偏的队列作为其中的一个排序因子适度影响最终的排序结果。这种设计实际上是在利用排序系统中的有限探索预算，为低流行度但具有较高潜在价值的内容提供额外的竞争机会。它的本质并不是简单地“惩罚热门内容”，而是降低历史流行度对模型排序结果的过度影响，防止推荐系统陷入过度的“马太效应”，同时也能够使模型更加充分地识别出那些尚未获得足够曝光、但在当前用户请求中具有较高匹配度的内容。

此外，我们还需要注意的是，流行度偏差的治理不能非黑即白地理解为“热门内容越少越好”。热门内容通常确实具有较高的用户价值，完全去除其流行度信息反而可能损害推荐效果，导致线上的 **AB** 核心指标产生大幅下跌。因此，更合理的目标是在利用历史反馈的准确性与避免历史流量分配进一步固化之间建立某种平衡的关系，即在保持热门内容具有合理曝光的同时，也为低流行度但具有潜在价值的内容提供公平的竞争机会。

从长期来看，流行度偏差实际上与推荐系统的探索问题密切相关。如果系统永远只选择当前预测分数最高的内容，那么模型很容易陷入由历史数据决定的局部最优；而适当引入低流行度内容的探索，则能够获得更多关于长尾内容真实用户价值的数据，从而改善后续模型训练的数据分布。因此，流行度偏差不仅是一个模型预估问题，同时也是一个流量分配和反馈闭环问题。在后续第33章节中我们也会继续探讨工业级推荐系统中的探索与利用问题，同时会在第27章中讨论因果推荐相关内容以及如何使用因果推荐的技术对本章节中介绍到的各种偏差进行纠偏处理。

19.8 样本拼接偏差

除样本选择偏差外，工业级推荐系统的训练数据还普遍受到一种容易被忽视的问题影响，即**样本拼接偏差 (Sample Joining Bias)**。以短视频推荐为例，用户对一次曝光的反馈并不总是即时完成：点击等行为可以较快返回，但观看时长、点赞、关注、评论等后续行为往往会在曝光后的数秒、数分钟甚至更长时间内陆续发生；在电商等场景中，下单、支付等转化行为的反馈延迟通常更长。因此，在某一时刻构建离线训练样本时，部分曝光对应的用户反馈尚未完全到达，已拼接出的标签只能反映一个不完整的行为状态。

与此同时，工业级推荐系统通常采用持续训练 (Continuous Training) 机制，不断将线上新增日志接入离线训练流程。即使数据链路支持近实时拼接，从曝光日志产生、行为日志回流，到多源数据关联并最终形成可训练样本，整个样本拼接过程本身仍不可避免地存在处理延迟。于是，训练时使用的样本标签与用户最终真实反馈之间会产生时间错位：一部分尚未发生或尚未回流的正反馈可能被暂时视为负反馈或缺失反馈。这种由**用户**

行为天然延迟与离线样本拼接链路延迟共同造成的标签不完整和时间错位，即为样本拼接偏差。

因此，在实时样本构建过程中，容易出现如下情况：

$$t \text{ 时刻曝光} \rightarrow t + \Delta t \text{ 时刻发生行为} \quad (19.33)$$

其中 Δt 表示用户行为相对于曝光发生的反馈延迟。如果系统按照当前时间窗口直接拼接曝光样本和行为标签，那么部分近期曝光样本实际上尚未获得完整的用户反馈。这些样本可能被错误地标记为负样本，或者由于标签尚未成熟而产生不完整的监督信号。以直播推荐为例，直播的观看时长通常跟视频观看不同，不会受到视频本身物理时长的限制，只要主播不关播，直播的观看时长就可以很长。因此，在时间 t 对用户曝光一个直播：

$$(u, i, t, e = 1) \quad (19.34)$$

其中 $e = 1$ 表示曝光发生，但用户直到 $t + 10min$ 才完成有效观看。如果训练系统在 $t + 5min$ 进行样本拼接，那么该样本此时还没有观察到最终观看行为。若直接将其作为负样本加入训练集，就会产生：

$$\hat{y}_{ui} = 0 \quad (19.35)$$

但真实标签实际上可能为：

$$y_{ui} = 1 \quad (19.36)$$

这种由曝光时间与反馈时间不一致所产生的标签错误，会进一步影响在线持续训练模型的稳定性。

样本拼接偏差在工业推荐系统中尤为明显，原因在于推荐模型通常采用实时或准实时训练机制。为了提高模型对用户兴趣变化的感知能力，推荐系统希望尽可能快地将新产生的用户行为加入训练数据；但与此同时，许多反馈行为具有天然的延迟性，过早构造训练样本时，点击、观看完成、转化等标签可能尚未充分成熟。因此，训练样本的构造需要在训练实时性与标签完整性之间进行权衡。如图 19.4 所示，较短的等待窗口能够使新行为更快进入训练流程，从而提升模型对用户兴趣变化的响应速度；但此时部分延迟反馈尚未到达，容易形成错误标签或缺失标签。相反，较长的等待窗口能够回收更完整的反馈信号，却会降低训练数据的新鲜度，使模型难以及时适应用户兴趣和内容环境的变化。在实际工程中，等待时间过长虽然能够获得更加完整的反馈标签，但模型无法及时感知用户兴趣变化；等待时间过短则能够提高训练实时性，却可能引入大量由延迟反馈造成的错误标签。



图 19.4: 样本拼接偏差中的训练实时性与标签完整性权衡。

针对这一问题，通常可以采用延迟反馈建模（Delayed Feedback Modeling）对用户行为发生的时间延迟进行显式建模。相关研究已经对持续训练场景中的延迟反馈问题进行了系统讨论，例如经典延迟反馈建模论文《Addressing Delayed Feedback for Continuous Training with Neural Networks in CTR Prediction》[1]。在工业实践中，一种较为简单的方法是设置标签的成熟窗口（Label Maturity Window），即对于曝光发生后的前 Δt 时间内的样本暂不参与训练：

$$\mathcal{D}_{train} = \{(u, i, y) \mid t_{feedback} - t_{exposure} \geq \Delta t\} \quad (19.37)$$

这里 Δt 可以取 20 分钟这种固定的值，具体取值需要根据工业界具体的业务以及样本拼接率的数据分析来决定。

通过这种方式，可以在一定程度上保证进入训练集的样本已经拥有相对完整的反馈。但是，固定等待窗口并不能完全解决问题，因为不同用户行为具有不同的反馈延迟分布。例如，点击通常在曝光后很快发生，而观看时长、关注以及长期留存等行为可能具有更加明显的延迟。

更合理的方法是针对不同任务分别建模反馈延迟，或者直接学习用户行为发生的概率分布。从更广泛的角度来看，样本拼接偏差实际上反映了推荐系统训练数据中的一个核心问题：即样本时间戳与标签时间戳的不一致问题。因此，在设计实时推荐模型训练系统时，不仅需要关注样本吞吐量和训练延迟，还需要同时考虑标签成熟度、反馈延迟分布以及不同任务之间的时间尺度差异。

19.9 工业实践

前面介绍的各种推荐偏差最终都会反映到工业推荐系统的线上流量分布中。如果只依靠离线训练数据进行偏差分析通常是不够的，因为离线数据本身通常已经受到了历史推荐策略的影响。如果希望真正获得更加接近无偏分布的数据，就需要在在线推荐系统中主动进行一定程度的探索。工业实践中比较常见的一种方式设计**随机无偏流量（Random Unbiased Traffic）**，即从正常推荐流量中划分出一部分实验流量，在受控范围内降低原有排序策略的影响，使不同候选内容获得更加接近随机的曝光机会。

我们假设正常推荐策略为：

$$\pi(i | u, x) \quad (19.38)$$

其中 u 表示用户， x 表示上下文信息， i 表示候选内容。正常情况下，内容获得曝光的概率高度依赖于模型排序结果：

$$P(e_i = 1) \approx \pi(i | u, x) \quad (19.39)$$

而在随机无偏流量中，可以在满足一定业务约束的情况下，对候选内容进行随机采样或者随机打散，使曝光概率尽可能降低对历史排序分数的依赖。例如，可以从候选集合 $\mathcal{I}_u$ 中按照一定策略随机选择内容：

$$i \sim \text{Uniform}(\mathcal{I}_u) \quad (19.40)$$

或者在控制用户体验的前提下，仅对候选集合中的部分内容进行随机化曝光。

随机无偏流量的核心价值并不是直接提升线上指标，而是**获得更加接近无偏的数据**。由于随机化降低了历史排序策略与内容曝光之间的相关性，因此用户后续产生的点击、播放、观看时长等行为可以更加真实地反映用户对内容本身的偏好。例如，对于两个内容 i_1 和 i_2 ，正常推荐策略可能长期优先曝光 i_1 ，即：

$$P(e_{i_1} = 1) \gg P(e_{i_2} = 1) \quad (19.41)$$

在随机无偏流量中，则可以人为提高 i_2 获得曝光的机会。当观察到用户在随机曝光条件下对 i_2 产生较高的交互行为时，就可以获得更加可靠的证据，判断 i_2 是否因为历史曝光不足而被低估。




图 19.5: 随机无偏流量的数据校准机制。

因此，随机无偏流量可以被理解为推荐系统中的一种**数据校准机制（Data Calibration Mechanism）**。常规的线上流量通常由推荐系统中的召回、排序策略产生，因此其中记录的用户反馈不可避免地混入了位置偏差、策略选择偏差以及历史模型自身的偏好等。为了获得更接近用户真实偏好的监督信号，推荐系统可以从主流量中划分一部分受控的随机探索流量，弱化既有排序策略对曝光机会的影响。如图 19.5 所示，随机无偏流量并不直

接替代常规推荐流量，而是作为独立的数据来源。它通过更随机的内容展示获得相对无偏的用户反馈，再将这些反馈用于校准或构造去偏训练数据。这样，模型可以减少将“内容因处于有利位置而获得的交互”误认为“内容本身具有更高用户价值”的风险。

在工业系统中，随机无偏流量通常不会占据很大的比例，而是通过独立的 AB 实验流量或探索流量进行精细控制。一方面，探索流量过低时，无偏样本数量有限，难以有效支撑偏差校正；另一方面，探索流量过高时，随机展示可能显著降低推荐相关性，进而影响用户体验、CTR、Duration 等线上业务指标。更加合理的工程实践是在保证主流量推荐效果的前提下，为不同场景配置适当比例的探索流量，并将其作为长期的数据校准来源。

随机无偏流量产生的数据还可以进一步用于多个方向。一方面，可以用于估计不同位置、不同内容以及不同用户群体的真实行为概率；另一方面，可以作为后续偏差校正模型的训练数据；此外，还可以用于离线评估推荐模型，降低由于历史曝光策略导致的评估偏差。从工业推荐系统的长期演进来看，随机无偏流量还有一个非常重要的价值，即**打破推荐系统自身形成的数据闭环**。如果模型永远只根据历史推荐结果产生的数据进行训练，那么系统很难发现历史模型没有探索到的内容价值。通过少量受控随机流量，可以不断为系统注入新的信息，使模型能够修正已有偏差。



图 19.6: 工业推荐系统中的偏差治理数据闭环。

因此，在实际推荐系统中，更完整的偏差治理不应止步于利用历史数据训练模型，而应形成持续校准的数据闭环。如图 19.6 所示，推荐系统以历史行为数据为基础完成模型训练和线上排序，并通过受控随机探索获取更接近无偏的用户反馈；这些反馈进一步用于模型更新，从而持续识别、校准和修正历史策略带来的偏差。这一过程体现了工业推荐系统从单纯“利用历史数据”向“利用与探索相结合”的演进。

需要注意的是，随机无偏流量并不意味着将全部线上流量随机化，而是应根据业务风险、流量规模和数据价值设置合理的探索比例。对于高风险或强商业约束场景，通常采用更保守的受控探索策略；对于新内容、冷启动内容和长尾内容，则可以适当增加探索机会。最终，工业推荐系统需要构建的并非只是追求短期排序指标的模型，而是一套能够持续发现真实用户偏好、识别并修正历史偏差、并通过线上反馈不断校准自身的数据与模型闭环。

19.10 推荐偏差的综合治理

从前面这些章节讲述到的几类推荐系统偏差可以看出，工业级推荐系统中的偏差往往不是单一模块造成的，而是数据、模型和线上策略共同作用的结果。因此，工业级推荐系统中的偏差治理通常需要从多个不同的层次来进行。首先，在数据层面，需要尽可能扩大训练数据的覆盖范围，增加探索样本以及随机曝光样本，并对不同用户群体、内容类型和曝光位置进行分层统计。数据层面的核心目标是让训练数据尽可能覆盖真实线上分布，而不是完全依赖历史推荐策略产生的数据。其次，在样本层面，可以通过重采样、重要性加权、负采样以及分人群或分垂类采样等方法降低不同群体之间的数据分布差异。例如，对于训练数据中出现频率过高的热门内容，可以适当降低其采样权重；对于长尾内容，则可以通过增加探索样本提高其训练覆盖率。再次，在模型层面，可以显式建模产生偏差的因素。例如，将用户的兴趣与曝光位置进行解耦，将视频 Duration 作为条件变量进行建

模，或者通过多任务学习分别预测用户行为和偏差因素的影响。进一步地，在目标函数层面，不能只关注单一的 CTR、VV 或者 Duration 指标，而需要同时考虑用户价值、内容生态以及长期收益。例如，可以将用户体验、多样性、新内容曝光和长期用户价值共同纳入优化目标。最后，在线上的推荐策略层面，需要通过探索与利用（Exploration and Exploitation）的平衡来避免整个推荐系统陷入到局部最优中。推荐系统不能永远只推荐当前最确定的内容，而应该保留一定比例的探索流量，为新用户、新内容和长尾内容提供获取反馈的机会。



因此，一个更完整的推荐系统偏差治理框架需要覆盖数据、采样、模型、目标和线上策略等多个环节。如图 19.7 所示，任一环节存在系统性偏差，都可能通过推荐反馈链路传导并影响其他环节。推荐系统偏差的治理不应仅聚焦于某个单独的模型模块，而应从数据生成、样本构造、模型学习、目标设计到线上策略进行系统化分析。从更加宏观的角度来看，推荐系统的偏差治理主要包含两类相互关联的问题。第一类是统计意义上的偏差校正，其目标是减弱数据与曝光机制带来的干扰，使模型能够更准确地估计用户对内容的真实偏好。第二类是业务意义上的偏差控制：即使某类内容在统计意义上具有更高的预估价值，系统仍需结合用户体验、内容生态和平台长期收益等因素进行约束。需要注意的是，推荐系统并非简单追求“消除所有 Bias”，而是需要识别不同 Bias 的产生机制，判断哪些偏差应当被校正，哪些偏差包含有效的用户偏好信息，以及哪些偏差需要在业务层面受到约束。

19.11 本章小结

推荐系统是一个典型的数据驱动闭环系统，其训练数据并不是独立、随机地产生的，而是由历史推荐策略、用户行为以及内容供给共同作用形成。因此，推荐系统中的偏差具有明显的系统性和累积性。本章首先对推荐偏差问题进行了整体概述，然后依次介绍了工业推荐系统中的几类典型偏差，包括样本选择偏差、用户群体偏差、混淆偏差、曝光位置偏差、Duration 偏差、流行度偏差以及样本拼接偏差，并在此基础上讨论了推荐偏差的工业实践和综合治理。

样本选择偏差主要来源于训练数据是历史推荐系统筛选后的结果，容易造成训练分布与真实候选空间之间的不一致；用户群体偏差主要来源于不同用户在活跃程度、历史行为数量和兴趣结构上的差异，容易导致模型对不同用户群体的建模能力不均衡；混淆偏差来源于多个因素同时影响用户行为，使模型容易将相关性错误理解为因果关系；曝光位置偏差来源于不同展示位置天然具有不同的用户交互概率；Duration 偏差则是短视频推荐中的典型问题，模型可能由于目标定义或者指标设计而产生对特定视频时长的系统性偏好；流行度偏差则可能通过“热门内容获得更多曝光、更多曝光产生更多反馈”的反馈循环进一步强化头部内容优势；样本拼接偏差则源于用户行为的天然延迟与离线样本拼接链路延迟共同造成的标签不完整和时间错位，是实时或准实时训练场景中一种容易被忽视但又普遍存在的问题，需要在训练实时性与标签完整性之间进行权衡。这些偏差之间还可能相互叠加。例如，一个热门内容更容易获得高曝光位置，高曝光又产生更多交互数据，更多交互数据进一步提高模型对该内容的估计价值，最终形成样本选择、位置和流行度偏差共同作用的结果。因此，推荐偏差并不是单独存在于某一个模型或者某一个模块中的问题，而是贯穿推荐系统全链路的重要问题。

在工业实践部分，本章进一步介绍了如何通过随机无偏流量来打破推荐系统自身形成的数据闭环，为偏差

校正和离线评估提供更接近真实分布的反馈信号；在推荐偏差的综合治理部分，则从数据、样本、模型、目标函数以及线上策略等多个层次系统地讨论了偏差治理的整体框架，强调偏差治理并非简单追求“消除所有 **Bias**”，而是需要识别不同偏差的产生机制，区分应当被校正的统计性偏差和需要在业务层面加以约束的偏差。

从推荐系统的发展来看，如何处理偏差实际上也是推荐模型从相关性建模走向因果建模、从短期指标优化走向长期价值优化的重要驱动力。后续章节将进一步围绕这一主线展开，在偏差问题的基础上介绍多目标优化、因果推断、强化学习以及生成式推荐等技术，并讨论这些方法如何帮助工业推荐系统获得更加准确、稳定和长期的优化能力。

19.12 参考文献

- [1] Sofia Ira Ktena et al. “Addressing delayed feedback for continuous training with neural networks in CTR prediction”. In: *Proceedings of the 13th ACM conference on recommender systems*. 2019, pp. 187–195.